

Programmation et projet encadré - L7TI005

Shell Unix

Crédits supports : Serge Fleury

Yoann Dupont prenom.nom@sorbonne-nouvelle.fr

Pierre Magistry pierre.magistry@inalco.fr

2023-2024

Université Sorbonne-Nouvelle

INALCO

Université Paris-Nanterre

Introduction



Existence et importance du système de fichiers

Tout est fichier

- dans les années 60, ce n'était pas évident,
- même les programmes, les périphériques, le réseau, . . .
- simplicité → on ne pense qu'en termes de fichiers et dossiers,
- d'où l'importance de bien les organiser !

Existence et importance du système de fichiers

Tout est fichier

- dans les années 60, ce n'était pas évident,
- même les programmes, les périphériques, le réseau, ...
- simplicité → on ne pense qu'en termes de fichiers et dossiers,
- d'où l'importance de bien les organiser !

Un ensemble de commandes pour manipuler les fichiers et leur contenu.

(depuis **la ligne de commandes**)

- Chaque commande doit faire **une** chose et la faire **bien** (K.I.S.S.)
- Chaque commande est pensée pour pouvoir interagir avec les autres.
- On fait des choses complexes en combinant des commandes simples.
(*pipelines* ou *scripts*)

Le Système de fichier



Points clefs

- les **fichiers** sont dans un **dossier**
- pouvant eux même être dans un **dossier** « parent »
- ce qui forme une **arborescence**

L'ensemble des données sur la machine sont regroupées en une seule **arborescence**, il est intéressant de pouvoir identifier les fichiers et les dossiers par un **chemin** dans l'arbre.

/ désigne la **racine** de l'arbre

~/ désigne le dossier personnel de l'utilisateur ("*HOME*")

./ désigne le dossier courant (*working directory*)

../ désigne le dossier parent

un **chemin** est formé par une suite de noms de dossiers séparés par des /, pouvant se finir par le nom d'un fichier.

un chemin absolu indique la position d'un fichier en partant de la **racine**.

ex: `/home/pierre/PPE1`

un chemin relatif indique la position d'un fichier en partant du dossier courant.

ex: `../../dev/input/mouse3`

→ habituez vous à toujours être capable de donner le chemin relatif et absolu vers les fichiers que vous manipulez.

Le système de fichier – Jokers ! (*wildcards*)

ou « caractères de remplacement »

Dans un chemin, caractères ? et * ont un comportement spécial.

- ? peut remplacer n'importe quel caractère (unique)

- * peut remplacer n'importe quelle suite de caractères

→ le chemin peut alors désigner plusieurs fichiers !

À tester avec la commande `ls`.

Les Commandes

Les commandes sont des fichiers comme les autres,

- qui ont la propriété d'être exécutables
- qui sont placés par convention dans un dossier où le système sait les trouver (typiquement `/usr/bin/`)

La syntaxe d'une commande

nom [-options...] [arguments...]

- les **options** peuvent avoir une forme courte (-o avec un seul tiret)
- ou une forme longue (--option avec deux tirets).
- Les **arguments** sont typiquement des chemins vers des fichiers (mais pas toujours).
- La première action de l'interpréteur de commande est de *tokeniser* la ligne pour découper le nom de la commande, les options et les arguments.

→ habituez vous à anticiper comment les lignes de commandes que vous saisissez vont être découper et à repérer nom, options et arguments, comme l'interpréteur

Quelques commandes à connaître

`cd, ls, pwd, cat, less, wc, echo, head, tail, mkdir, cp, mv, rm, rmdir, file...`

Et surtout: `man`

La plupart des commandes ont aussi une option `--help` qui permet d'obtenir une description concise du fonctionnement et des options de la commande

Se promener dans l'arbre

pwd *print working directory*

ls *list* le contenu d'un dossier

cd *change directory*

cp *copy*

mv *move* déplacer

rm *remove* supprimer

mkdir *make directory* créer un dossier

touch crée un fichier (effet de bord bien pratique)

file donne des informations sur le type de fichier

cat lit le contenu d'un ou plusieurs fichiers

head lit le début d'un fichier


tail lit la fin d'un fichier

cut sélectionne une ou plusieurs colonnes dans un fichier tabulé

less lecteur (interactif)

- Télécharger l'archive `fichiers.zip` ...
- créer un dossier de travail où la décompresser
- créer une arborescence pour classer les documents
 - par type de fichier
 - puis par date pour les txt et ann
 - puis par lieux pour les photos.

Exercice



Consignes

- Télécharger l'archive `fichiers.zip` ...
- créer un dossier de travail où la décompresser
- créer une arborescence pour classer les documents
 - par type de fichier
 - puis par date pour les `txt` et `ann`
 - puis par lieux pour les photos.(Voir ci-contre)
- copier les fichiers dans les dossiers correspondants

Les Pipelines



Généralités

Toutes les commandes communiquent via trois flux de données

stdin l'entrée standard (par défaut le clavier)

stdout la sortie standard (par défaut l'écran)

stderr la sortie d'erreurs standard (par défaut l'écran)

Par défaut, les commandes échangent dans le terminal via le clavier et l'écran, mais on peut **rediriger** ces flux.

Redirections vers et depuis des fichiers


- < remplace le clavier par le contenu d'un fichier
- > écrit stdout dans un fichier
- 2> écrit stderr dans un fichier
- >& écrit stdout et stderr dans un fichier

En écriture, si on double le chevron (», »&, 2»), on écrit en ajoutant la sortie à la fin d'un fichier.

ATTENTION: les chevrons simples (>, >&, 2>) écrasent le fichier si il existe déjà.


WC

Situation par défaut



```
wc < fic.txt
```


Redirection du contenu d'un fichier dans stdin



ATTENTION: ici `fic.txt` n'est PAS un argument.

```
wc fic.txt > output.txt
```

Redirection de stderr dans un fichier.




ATTENTION: ici `fic.txt` est donné en argument (et `wc` ignore l'entrée standard).

La sortie standard reste l'écran par défaut.


```
wc fic.txt 2> errors.txt
```


Redirection de stderr dans un fichier.



ATTENTION: ici `fic.txt` est donné en argument (et `wc` ignore l'entrée standard).

```
wc fic.txt >& output.txt
```

Redirection des sorties `stdin` et `stdout` dans un fichier.



ATTENTION: ici `fic.txt` est donné en argument (et `wc` ignore l'entrée standard).

Redirections entre les commandes


Plusieurs commandes peuvent communiquer en connectant les sorties aux entrées aux moyen du caractère «pipe» |

`cmd1 | cmd2` la sortie standard (stdout) de `cmd1` est envoyée en stdin de `cmd2`.

`cmd1 |& cmd2` les sorties stdout et stderr de `cmd1` sont toutes deux redirigées vers stdin de `cmd2`.

```
cat *.txt | grep université | wc > output.txt
```

Redirection de stderr dans un fichier.



Quelques commandes de plus

grep recherche de motifs dans l'entrée (ou dans des fichiers)

sort trier des lignes

uniq supprimer les lignes qui se répètent

avec les fichiers *.ann, Sauriez vous... ?

- Compter le nombre d'annotations par année (2016, 2017 et 2018),
- limiter ce comptage aux lieux (Location),
- sauvegarder ces résultats dans un (seul) fichier,
- établir le classement des lieux les plus cités.
- trouver les annotations les plus fréquentes pour votre mois de naissance, toutes années confondues.

Introduction aux scripts



Problème du saut de ligne manquant

Comparer

- `cat 2016*.ann | wc -l` (*faux*)
- `sort 2016*.ann | wc -l` (*juste, mais lent*)
- `grep "" 2016*.ann | wc -l` (*mieux*)

Pour changer l'année, on ne retape pas tout !

on peut utiliser **grep**

on peut utiliser **grep**

Grep

- `grep "Location" 2016*.ann | wc -l`
- `grep "Location" 2017*.ann | wc -l`
- `grep "Location" 2018*.ann | wc -l`

Pour changer l'année, on ne retape pas tout !

Corrections – sauvegarder les résultats

On utilise les redirections de sortie standard Comparer `>` et `>>`

la commande `echo`

- `echo "bonjour"` → affiche bonjour
- `echo "bonjour" > sortie.txt` → écrit bonjour dans un fichier (nouveau ou écrase le contenu)
- `echo "tout le monde" >> sortie.txt` → ajoute bonjour à la fin du fichier

Corrections – sauvegarder les résultats

On utilise les redirections de sortie standard Comparer `>` et `>>`

la commande echo

- `echo "bonjour"` → affiche bonjour
- `echo "bonjour" > sortie.txt` → écrit bonjour dans un fichier (nouveau ou écrase le contenu)
- `echo "tout le monde" >> sortie.txt` → ajoute bonjour à la fin du fichier

Solution

```
echo "pour l'année 2016" > sortie.txt
grep "Location" 2016*.ann | wc -l >> sortie.txt
echo "pour l'année 2017" >> sortie.txt
grep "Location" 2017*.ann | wc -l >> sortie.txt
echo "pour l'année 2018" >> sortie.txt
grep "Location" 2018*.ann | wc -l >> sortie.txt
```

Un premier script

la commande `bash`

Une commande comme les autres qui **interprète des commandes**

- depuis l'entrée standard
- ou depuis un fichier → un **script** !

voir `premier_script.sh`

Il suffit donc d'écrire des commandes dans un fichier texte pour obtenir un script.
On peut :

- ajouter des commentaires `#`
- ajouter un *shebang* `#!/usr/bin/bash`
- rendre le fichier exécutable (avec **`chmod +x`**)

- écrire un script qui donne le nombre de Location par année
- ajoutez-le à votre git

Arguments et variables

Arguments d'un script

Les commandes peuvent recevoir des arguments

- Ça permet de ne pas faire toujours la même chose
- souvent le même traitement sur des données différentes
- ou un traitement légèrement différent

Dans un script bash

Par convention, au début de l'exécution d'un script, l'interpréteur donne la valeur des arguments aux **variables** \$1 \$2 \$3 ...

dans l'ordre d'apparition sur la ligne de commande.

- On peut les utiliser dans notre script
(ex: faites un script qui contient uniquement la commande echo \$2 et testez son comportement)
- Un bon usage est de créer de nouvelles variables avec un nom plus explicite.
exemple: FICHER_URLS=\$1

Les variables en bash

Affectation

On donne une valeur à une variable avec le signe =

- sans espace `FICHER=urls.txt`
- avec des " ou ' si il y a des espaces
`MSG="Bonjour tout le monde"`
- on peut aussi stocker le resultat d'une commande en l'écrivant dans `$()`
ex: `NB_LIGNES=$(wc -l $FICHER)`

Utilisation

On fait référence à la valeur d'une variable en prefixant son nom d'un \$

- sera remplacé dans une chaîne entre " (doubles)
- mais pas entre ' (simples)

(tout ça marche aussi bien dans un script que en mode interactif).

Exercice 1

- copier le premier script
- le modifier pour que l'année et le type d'entité soient donnés en argument du programme.
- modifier le premier script pour qu'il appelle le second afin de produire le même résultat.

Exercice 2

- créer un script pour établir le classement des lieux les plus cités.
- prendre en argument l'année, le mois et le nombre de lieux à afficher
- accepter * pour l'année et le mois.

Pensez à faire des **commit** et **push** vers vos dépôt git au fur et à mesure !

Instructions de contrôle

Besoin

On doit être capable d'effectuer certains traitements seulement si une condition particulière est vérifiée

- Si telle condition est vraie alors on fait le traitement A, sinon on fait le traitement B
- Si les arguments sont corrects, je lance le programme, sinon j'émet un message d'erreur et j'arrête le script.

Instructions conditionnelles

Besoin

On doit être capable d'effectuer certains traitements seulement si une condition particulière est vérifiée

- Si telle condition est vraie alors on fait le traitement A, sinon on fait le traitement B
- Si les arguments sont corrects, je lance le programme, sinon j'émets un message d'erreur et j'arrête le script.

l'instruction if

```
if [ condition ]  
then  
    echo "la condition est valide"  
else  
    echo "la condition n'est pas valide"  
fi
```

Conditions possibles

Sur les chemins

- f fichier** vrai si le fichier existe
- d dossier** vrai si le dossier existe
- s fichier** vrai si le fichier existe et n'est pas vide

Sur des chaînes de caractères

- = **ou** != tester si deux chaînes sont identiques (=) ou différentes (!=)
- < **ou** > pour déterminer si in chaîne est avant ou après une autre dans l'ordre alphabétique
- n chaine** vrai si la chaîne n'est pas vide
- z** vrai si la chaîne est vide (ex: argument non fourni)

Conditions possibles (suite)

Sur les entiers

a -eq b si a est égal à b (**e**qual)

a -ne b si a est différent de b (**n**ot **e**qual)

a -lt b si a est plus petit que b (**l**ess **t**han)

a -gt b si a est plus grand que b (**g**reater **t**han)

a -le b si a est inférieur ou égal à b

a -ge b si a supérieur ou égal à b

Conditions possibles (suite)

Avec des doubles crochets, il est possible d'utiliser des expressions régulières pour tester des chaînes

exemple

```
if [[ $1 =~ bon(jour|soir) ]]
then
    echo "salut"
fi
```

→ Testons tout ça ensemble...

Une bonne habitude

Le premier usage (pas le seul) de ces tests est de vérifier que toutes les conditions sont réunies pour que le traitement se passe bien avant de lancer les calculs. Et d'informer l'utilisateur de tout problème

- Les fichiers attendus existent-ils ?
- Les arguments ont-ils le bon format ?
- on peut arrêter l'exécution du script à tout moment avec la commande **exit**

Une bonne habitude

Le premier usage (pas le seul) de ces tests est de vérifier que toutes les conditions sont réunies pour que le traitement se passe bien avant de lancer les calculs. Et d'informer l'utilisateur de tout problème

- Les fichiers attendus existent-ils ?
- Les arguments ont-ils le bon format ?
- on peut arrêter l'exécution du script à tout moment avec la commande **exit**

Exercice

- Modifier vos programmes pour qu'ils valident leurs arguments et se terminent si il y a un problème.
- synchroniser votre git !

Répéter des actions sans répéter le code

- appliquer le même traitement
- à des données (variables) différentes
- en séquence

Les boucles FOR (« pour tout élément, faire... »)

```
N=0
for ELEMENT in a b c d e
do
    N=$((expr $N + 1))
    echo "le $N ieme élément est $ELEMENT"
done
```

Les boucles FOR

remarques

- le choix du nom de la variable est libre
- la commande **expr** est une calculatrice
- on utilise souvent une commande pour générer la liste d'éléments (à tester)

Les boucles FOR (« pour tout élément, faire... »)

```
N=0
for ELEMENT in a b c d e
do
    N=$((expr $N + 1))
    echo "le $N ieme élément est $ELEMENT"
done
```

Les boucles WHILE

Les boucles WHILE (« tant qu'une *condition* est vraie, on recommence... »)

```
while [ condition ];  
do  
    echo "je continue à boucler";  
done
```

remarques

- les conditions sont similaires à celles des **IF**
- la commande **read** est souvent utilisée avec **WHILE** («tant qu'il y a quelque chose à lire, on le traite») → démo.
- attention aux boucles infinies ! (CTRL-C pour arrêter brutalement le programme).

Example: lire et expliquer ce code

```
#!/usr/bin/bash
if [ $# -ne 1 ]
then
    echo "ce programme demande un argument"
    exit
fi
FICHIER_URLS=$1
OK=0
NOK=0
while read -r LINE;
do
    echo "la ligne: $LINE"
    if [[ $LINE =~ ^https?:// ]]
    then
        echo "ressemble à une URL valide"
        OK=$((expr $OK + 1))
    else
        echo "ne ressemble pas à une URL valide"
        NOK=$((expr $NOK + 1))
    fi
done < $FICHIER_URLS
echo "$OK URLs et $NOK lignes douteuses"
```

Point d'étape



De belles choses

- Projet méli-mélo <https://github.com/Sazuna/PPE1>
- Exercices exemple ici <https://github.com/LeaMondoloni/PPE1>
ou là <https://github.com/FlorianJacquot/PPE1>
- commits même en cas de difficultés

De belles choses

- Projet méli-mélo <https://github.com/Sazuna/PPE1>
- Exercices exemple ici <https://github.com/LeaMondoloni/PPE1>
ou là <https://github.com/FlorianJacquot/PPE1>
- commits même en cas de difficultés

Mais aussi

- des gits vides ou presque
- et des surprises
 - création d'un drive
 - urls numérotées <https://github.com/AlinaMV/PPE1/blob/main/URLs.txt>

1. Compter \$TYPE d'entités par \$ANNEE
 - basique
 - avec arguments
 - en validant les arguments avec des et **exit** si problème.
2. classement des lieux les plus cites
 - par \$ANNEE et \$MOIS en limitant à \$TOPN résultats plus nombreux
 - en validant les arguments
3. Lecture du code diapo 41

Remarques

Bien *commiter* à chaque étape permet de continuer à travailler dans le même fichier.

Quelques recommandations

- Penser à créer vos dépôts partagés
- Documenter vos réflexions et avancées
- Ajouter vos fichiers d'URL sur le Git
- Penser à la gestion de l'arborescence et des chemins (pwd, scripts, données)

Quelques mots à discuter: *fast-food*, *lecture*, *migration*